Universidad Católica San Pablo

FACULTAD DE INGENIERÍA Y COMPUTACIÓN

DEPARTAMENTO DE CIENCIA DE LA COMPUTACIÓN

Escuela Profesional de Ciencia de la Computación

Framework de destilación de conocimiento espacio-temporal para Action Quality Assessment en dispositivos con recursos limitados

Tesis

Presentada por el bachiller

Emmanuel Samir Galdos Rodriguez

Para Optar por el Título profesional de:

Licenciado en Ciencia de la Computación

Asesor: Dr./Mg. Edward Jorge Yuri Cayllahua Cahuina

Arequipa, Mes 2025

Aquí deberás colocar a quien va dedicada tu tesis por ejemplo: A Dios, por todo lo que me ha dado, a todos los profesores por sus enseñanzas y algunos amigos.

Abreviaturas

AQA *Action Quality Assessment*

KD *Knowledge Distillation*

I3D *Inflated 3D ConvNet*

TSM *Temporal Shift Module*

Agradecimientos

Aquí deberás colocar a quien y porque agradeces. Ejemplo:

En primer lugar deseo agradecer a Dios por haberme guiado a lo largo de estos cinco años de estudio.

Agradezco a mis padres por el apoyo brindado para forjarme como un profesional.

Agradezco a la universidad, mi *alma matter*, por haberme cobijado y brindado la formación que ahora me permitirá ayudar a construir una mejor sociedad.

Agradezco de forma muy especial a mi asesor Prof. Dr./Mag. nombre 1 por haberme guiado en esta tesis. ...

Deseo agradecer de forma especial a mis profesores: nombre 1, nombre 2, nombre 3 porque fueron ejemplos que deseo seguir en mi vida profesional.

Deseo agradecer al personal administrativo de la universidad: nombre 1, nombre 2, nombre 3. Muchas gracias por la atención brindada y porque siempre estuvieron dispuestas a ayudarnos.

Resumen

La Evaluación de la Calidad de Acciones (*Action Quality Assessment*, AQA) busca cuantificar objetivamente la calidad de ejecución de acciones humanas en video. Los modelos de referencia, como I3D, alcanzan alta precisión pero presentan un coste computacional elevado. Esta tesis propone un *framework* de destilación de conocimiento Teacher–Student que transfiere el rendimiento de un Teacher I3D preentrenado en Kinetics-400 hacia arquitecturas livianas (TSM-MobileNetV2 y MobileNetV3), combinando tres señales de supervisión: regresión sobre la etiqueta, alineación de mapas de atención espacio-temporal y alineación de representaciones intermedias en el tiempo. La propuesta se evalúa en AQA-7, MTL-AQA y JIGSAWS, cubriendo deporte multi-disciplina, clavados y cirugía robótica, con métricas de precisión y de eficiencia, incluyendo transferencia cruzada entre dominios. Los Students livianos alcanzan SRCC muy próximos al Teacher (brecha < 0.01) utilizando cerca del 7–9 % de sus FLOPs. La destilación sólo mejora de manera clara al Student que carece de módulos temporales explícitos (MobileNetV3 en AQA-7, +0.040 SRCC); en los demás casos la destilación no aporta o degrada. Este hallazgo, junto con la constatación de que la transferencia zero-shot entre dominios muy distintos (deporte $\rightarrow$ cirugía) fracasa, reabre la pregunta sobre el ámbito real de aplicabilidad de la destilación espacio-temporal en AQA y sugiere trabajar hacia destilación multimodal y adaptación de dominio.

Abstract

Action Quality Assessment (AQA) busca cuantificar objetivamente la calidad de ejecución de acciones humanas en video, con aplicaciones en deporte, rehabilitación y educación. El estado del arte se apoya en arquitecturas 3D profundas como I3D que alcanzan alta precisión pero presentan un coste computacional elevado que impide su despliegue en dispositivos con recursos limitados. Esta tesis aborda cómo transferir el rendimiento de modelos complejos de AQA hacia arquitecturas livianas preservando precisión competitiva y habilitando su uso en entornos restringidos. Se propone un framework de destilación Teacher–Student con tres señales complementarias: regresión directa sobre la etiqueta, alineación de mapas de atención espacio-temporal, y alineación temporal de representaciones intermedias. El Teacher es un I3D preentrenado en Kinetics-400; los Students son TSM-MobileNetV2 y MobileNetV3. El framework se evalúa en AQA-7, MTL-AQA y JIGSAWS, cubriendo deporte multi-disciplina, clavados especializados y cirugía robótica, mediante métricas de precisión (SRCC, PLCC, MAE) y eficiencia (FLOPs, latencia), incluyendo experimentos de generalización cruzada entre dominios. Los Students livianos alcanzan correlaciones SRCC muy cercanas al Teacher (0.897, 0.880 y 0.837 frente al Teacher en 0.905, 0.887 y 0.836 en los tres datasets respectivamente) utilizando sólo 7–9 % de los FLOPs y reduciendo la latencia a menos del 40 %. La destilación propuesta produce resultados heterogéneos: mejora al Student únicamente cuando éste carece de módulos temporales explícitos (MobileNetV3 en AQA-7, +0.040 SRCC), y degrada el rendimiento en las arquitecturas que ya modelan temporalidad (TSM-MobileNetV2). Un hallazgo central del trabajo es que, con pesos ImageNet modernos y pipeline adecuado, los Students livianos ya son suficientemente precisos para AQA sin destilación, reabriendo la pregunta sobre cuándo es realmente necesaria la destilación espacio-temporal en este tipo de tareas. La contribución principal es un benchmark reproducible en tres dominios, un análisis empírico crítico del alcance del KD para AQA, y la evidencia de que el verdadero ahorro computacional ya es accesible sin destilación adicional, orientando trabajos futuros hacia destilación multimodal o adaptación de dominio para escenarios trans-dominio.

Índice general

1. Introducción **2**

1.1. Motivación y Contexto 2

1.2. Planteamiento del Problema 3

1.3. Objetivos 4

1.3.1. Objetivo General 4

1.3.2. Objetivos Específicos 4

1.4. Organización de la Tesis 4

2. Marco Teórico **6**

2.1. Evaluación de la Calidad de Acciones 6

2.1.1. Definición y desafíos 6

2.1.2. Datasets y métricas 7

2.2. Distilación de Conocimiento 8

2.2.1. Principios y variantes 8

2.2.2. Distilación en visión por video 9

3. Estado del Arte **10**

3.1. Distilación en AQA: avances recientes 10

3.1.1. Distilación intermodal: de múltiples flujos a RGB 10

3.1.2. Auto-distilación con supervisión multiescalar 11

3.1.3. Distilación multimodal *vision–language* 12

3.1.4. Distilación temporal con alineación dinámica 13

3.2. Síntesis y brechas detectadas 14

4. Propuesta **15**

4.1. Planteamiento de la solución 15

4.2. Modelos seleccionados 16

4.2.1. Modelo Teacher 17

4.2.2. Modelos Students 17

4.3. Datasets y preprocesamiento 18

4.3.1. Conjuntos de datos 18

4.3.2. Preprocesamiento 19

4.3.3. Consideraciones técnicas 20

4.4. Metodología de Evaluación 21

4.4.1. Métricas de Precisión 21

4.4.2. Métricas de Eficiencia 21

4.4.3. Protocolo Experimental 22

4.4.4. Análisis Adicionales 22

5. Pruebas y Resultados **24**

5.1. Precisión en la Predicción 24

5.2. Eficiencia Computacional 25

5.3. Visualización de Atenciones 26

5.4. Generalización Cruzada 27

6. Conclusiones y Trabajos Futuros **29**

6.1. Conclusiones por Objetivos Específicos 29

6.2. Problemas encontrados 30

6.3. Recomendaciones 31

6.4. Trabajos futuros 31

Bibliografía **34**

Índice de tablas

2.1. Principales datasets empleados en *Action Quality Assessment* (AQA). . . . 8

3.1. Resumen de trabajos relevantes en distilación aplicada a AQA. 14

5.1. Resultados de precisión en los datasets evaluados. Valores obtenidos con semilla 42 sobre el test split oficial de cada dataset. 25

5.2. Comparación de eficiencia computacional entre modelos (batch 1, T = 64, RTX 3060 Mobile). 26

5.3. Evaluación cruzada entre dominios sin fine-tuning. Modelo entrenado en *source* y evaluado sobre el test split de *target*. 27

Índice de figuras

Capítulo 1

Introducción

1.1. Motivación y Contexto

En los últimos años, el reconocimiento automático de acciones humanas en video ha emergido como un área clave dentro del campo de la visión por computadora, con aplicaciones que abarcan desde la seguridad y el entretenimiento hasta la medicina y el deporte. No obstante, más allá de identificar qué acción se realiza en un video, ha cobrado gran relevancia una tarea más compleja: la **Evaluación de la Calidad de Acciones** (*Action Quality Assessment*, AQA). Esta disciplina busca medir la calidad con la que se ejecuta una acción, considerando criterios como la técnica, la fluidez y la precisión del movimiento. A diferencia del reconocimiento de acciones, AQA introduce desafíos adicionales tanto en términos de modelado como de evaluación.

El interés por AQA ha crecido sustancialmente debido a su potencial impacto en contextos donde el desempeño técnico es crítico. En el ámbito deportivo, por ejemplo, entrenadores y atletas pueden aprovechar sistemas automáticos para recibir retroalimentación objetiva y detallada que complemente la evaluación humana, reduciendo sesgos y mejorando el entrenamiento personalizado. De igual forma, en el campo de la rehabilitación física, los profesionales de la salud podrían beneficiarse del uso de modelos que evalúan en tiempo real la correcta ejecución de ejercicios terapéuticos, facilitando así el seguimiento remoto de pacientes y disminuyendo la necesidad de supervisión constante.

A pesar de estos beneficios potenciales, uno de los principales obstáculos para la adopción de sistemas de AQA en escenarios reales radica en su elevada demanda computacional. Modelos de alto rendimiento, como los basados en arquitecturas tridimensionales profundas (por ejemplo, I3D), han demostrado una alta precisión al capturar patrones espacio-temporales complejos. Sin embargo, su tamaño y costo computacional los hacen inviables para aplicaciones que requieren baja latencia, eficiencia energética o procesamiento local. Esto pone en evidencia la necesidad urgente de soluciones más eficientes, capaces de ofrecer resultados competitivos sin depender de infraestructuras costosas o de alto consumo.

En este contexto, arquitecturas livianas como *Temporal Shift Module* (TSM) y MobileNet-V3 se presentan como alternativas prometedoras. Estas redes son ampliamente

utilizadas en entornos con recursos limitados debido a su eficiencia, facilidad de implementación y disponibilidad en plataformas como Google Colab o incluso dispositivos móviles. No obstante, cuando se entrenan desde cero en tareas complejas como AQA, estas arquitecturas suelen mostrar una pérdida significativa de rendimiento en comparación con modelos más complejos.

Para enfrentar este dilema, la **distilación de conocimiento** (*Knowledge Distillation*, *Knowledge Distillation* (KD)) surge como una estrategia efectiva. Mediante esta técnica, se transfiere el conocimiento aprendido por un modelo complejo (denominado *Teacher*) a una arquitectura más ligera (*Student*), con el objetivo de replicar su comportamiento de forma más eficiente. Aunque existen trabajos que aplican KD en tareas generales de visión por computadora, la combinación específica de mecanismos de atención espacio-temporal y alineación temporal ha sido poco explorada dentro del contexto de AQA. Esta brecha representa una oportunidad metodológica valiosa para avanzar hacia soluciones más prácticas y generalizables.

1.2. Planteamiento del Problema

Diversas investigaciones han demostrado que los modelos profundos especializados en tareas de AQA, como los basados en I3D, pueden alcanzar altos niveles de rendimiento al capturar patrones espacio-temporales complejos presentes en las acciones humanas. No obstante, su alto costo computacional, tanto en términos de tiempo de inferencia como de consumo energético, los hace inadecuados para escenarios de bajo consumo o de procesamiento en tiempo real.

La creciente necesidad de ejecutar modelos de inteligencia artificial en dispositivos con recursos limitados ha impulsado la exploración de arquitecturas más ligeras, como TSM o MobileNet-V3. Sin embargo, estas alternativas, aunque eficientes, suelen presentar una pérdida de precisión considerable al ser entrenadas desde cero en tareas complejas como AQA. Por tanto, se requiere un mecanismo que permita combinar lo mejor de ambos mundos: la precisión de los modelos pesados y la eficiencia de los modelos livianos.

A partir de esta problemática, surge la siguiente **pregunta de investigación**:

> **¿Cómo optimizar el proceso de transferencia de conocimiento desde un modelo complejo de AQA hacia una arquitectura más ligera, de manera que se preserve un rendimiento aceptable y se habilite su uso en entornos con recursos computacionales limitados?**

Responder a esta pregunta requiere el diseño de una estrategia de distilación adaptada específicamente al dominio del análisis de video, considerando tanto las características espacio-temporales de la tarea como las capacidades diferenciadas de las arquitecturas *Teacher* y *Student*.

1.3. Objetivos

1.3.1. Objetivo General

Desarrollar una metodología eficiente de distilación de conocimiento que permita transferir el rendimiento de un modelo complejo basado en I3D hacia arquitecturas livianas, como TSM y MobileNet-V3, aplicadas a la evaluación de la calidad de acciones humanas en video.

1.3.2. Objetivos Específicos

- Investigar el estado del arte en técnicas de AQA y distilación de conocimiento en visión por computadora, identificando enfoques previos exitosos y sus limitaciones.
- Diseñar una estrategia de distilación que integre mecanismos complementarios, como el alineamiento de mapas de atención espacio-temporales y la sincronización de representaciones intermedias en el tiempo.
- Implementar y entrenar modelos *Student* livianos, utilizando conjuntos de datos estándares de AQA y empleando como referencia un modelo *Teacher* basado en I3D preentrenado.
- Evaluar experimentalmente la eficacia de la estrategia propuesta mediante métricas de precisión (SRCC, PLCC, MAE) y de eficiencia computacional (tiempo de inferencia, uso de memoria, FLOPs).
- Comparar el rendimiento de los modelos distilados con sus versiones sin distilación y con otras arquitecturas modernas, analizando los beneficios concretos de la metodología desarrollada.

1.4. Organización de la Tesis

El presente documento está estructurado de la siguiente manera:

- **Capítulo 2: Marco Teórico** - Fundamentos de *Action Quality Assessment* (AQA) y Distilación de Conocimiento (KD), incluyendo métricas clave (SRCC, PLCC, MAE) y conjuntos de datos (AQA-7, MTL-AQA, JIGSAWS).
- **Capítulo 3: Estado del Arte** - Revisión de técnicas recientes en KD para AQA, con énfasis en distilación intermodal y auto-distilación multiescalar.
- **Capítulo 4: Propuesta** - Metodología completa con:
  - Modelos: I3D (Teacher) y TSM/MobileNet-V3 (Students).
  - Mecanismos de distilación (atención espacio-temporal y alineación de características).

- Pipeline de preprocesamiento y evaluación.

- **Capítulo 5: Resultados** - Análisis comparativo de modelos distilados vs. baseline, métricas de precisión y eficiencia.
- **Capítulo 6: Conclusiones** - Hallazgos clave, limitaciones y direcciones futuras para KD en AQA.

Capítulo 2

Marco Teórico

En este capítulo se exponen los fundamentos teóricos necesarios para comprender la evaluación de la calidad de acciones (AQA) y la distilación de conocimiento (KD) en el contexto de visión por computador. Se abordan las definiciones, desafíos inherentes, métricas de evaluación y estructuras arquitectónicas clave que sustentan la propuesta metodológica desarrollada en esta tesis.

2.1. Evaluación de la Calidad de Acciones

2.1.1. Definición y desafíos

La AQA tiene como objetivo cuantificar objetivamente la calidad de ejecución de acciones humanas capturadas en video. A diferencia de las tareas tradicionales de clasificación de acciones, donde se identifica qué acción se realiza, en AQA se mide la competencia, técnica, fluidez y precisión con que se realiza dicha acción [Zhou et al., 2025]. Esta característica hace que la tarea sea particularmente exigente, pues implica una comprensión profunda del contenido visual y de las dinámicas temporales.

Limitaciones de los conjuntos de datos

Escasez de muestras y desequilibrio. Los conjuntos de datos disponibles en AQA tienden a ser específicos de dominios muy concretos, como el clavado olímpico o la gimnasia artística. Esto conlleva una limitada diversidad de escenarios y una reducida cantidad de ejemplos etiquetados, lo cual complica el aprendizaje generalizable [Wang et al., 2019]. Además, las etiquetas de calidad suelen distribuirse de forma sesgada, con acumulaciones en puntajes medios, lo que penaliza la capacidad de los modelos para identificar instancias en los extremos de calidad [Wang et al., 2024].

Anotaciones subjetivas. Las etiquetas suelen derivarse de la evaluación humana, típicamente por jueces expertos. Esta subjetividad introduce variabilidad y ruido en las etiquetas. Técnicas como el coeficiente κ de Cohen o la correlación interevaluador se utilizan para medir consistencia, pero el proceso sigue siendo costoso y propenso a sesgos [Li et al., 2019].

Generalización y adaptabilidad. Los modelos tienden a especializarse en un dominio específico y fallan al generalizar a nuevos tipos de acción o entornos sin un proceso de reentrenamiento. Las estrategias de aprendizaje multitarea y adaptación de dominio han mostrado avances limitados en este aspecto [Parmar and Morris, 2019].

Retos computacionales

Complejidad espacio–temporal. Capturar dependencias espaciales y temporales de forma conjunta exige arquitecturas profundas que trabajen con secuencias completas. Modelos como *Inflated 3D ConvNet* (I3D) operan con convoluciones 3D que implican un alto costo computacional y grandes requerimientos de memoria [Carreira and Zisserman, 2017].

Latencia y tiempo real. La evaluación de calidad en tiempo real es relevante para aplicaciones móviles o sistemas de retroalimentación inmediata. Modelos livianos como TSM o MobileNet-V3 sacrifican parte de su precisión para lograr una menor latencia de inferencia, lo que plantea un desafío al balancear velocidad y exactitud [Howard et al., 2019, Wang et al., 2024].

Variabilidad intra-clase

Acciones de la misma categoría pueden diferir en estilo, velocidad, o incluso en perspectiva de grabación. Esta variabilidad intra-clase dificulta la generación de representaciones robustas que capten la esencia de lo que constituye una ejecución "de calidad". Un ejemplo claro se da en los clavados olímpicos, donde ejecuciones técnicamente distintas pueden ser igualmente válidas, dependiendo del estilo del atleta [Pirsiavash et al., 2014, Yu et al., 2021].

2.1.2. Datasets y métricas

En la Tabla 2.1 se enumeran los principales datasets empleados en tareas de AQA, destacando su dominio de aplicación, la escala de puntuación y las métricas de evaluación.

Las métricas más utilizadas incluyen:

- **SRCC (Spearman Rank Correlation Coefficient)**: mide la correlación entre el orden de las predicciones y las etiquetas reales.

- **PLCC (Pearson Linear Correlation Coefficient)**: evalúa la relación lineal entre puntuaciones predichas y reales.
- **MAE (Mean Absolute Error)**: cuantifica el error promedio absoluto entre predicción y verdad de terreno.

Tabla 2.1: Principales datasets empleados en AQA.

Dataset	**Año**	**Descripción y métricas**
MIT-Diving	2014	370 videos de clavados olímpicos, puntuación humana [0–100], métricas: SRCC, PLCC, MAE [Pirsiavash et al., 2014].
UNLV-Vault	2018	176 videos de salto de gimnasia, puntuaciones [0–20], SRCC, MAE [Wang et al., 2022].
AQA-7	2017	1 189 videos de siete deportes (clavados, gimnasia, esquí, etc.), anotaciones detalladas, SRCC, PLCC, MAE [Parmar and Morris, 2017].
MTL-AQA	2019	1 412 videos de clavados (plataforma y trampolín), clasificación multietiqueta y regresión de puntuación [Parmar and Morris, 2019].
JIGSAWS	2013	Videos de suturas quirúrgicas, métricas de precisión de movimiento para AQA en cirugía robótica [DiPietro et al., 2013].

2.2. Distilación de Conocimiento

2.2.1. Principios y variantes

La distilación de conocimiento (KD) permite transferir información desde un modelo complejo y de alto rendimiento (Teacher) a un modelo más pequeño y eficiente (Student), con el objetivo de preservar la mayor cantidad de conocimiento posible. Esta técnica ha demostrado ser eficaz tanto en tareas de clasificación como de regresión, especialmente cuando se desea desplegar modelos en entornos con restricciones de cómputo [Hinton et al., 2015].

Los principales enfoques de distilación son:

- **Offline:** el Teacher se entrena previamente y sus parámetros permanecen fijos durante el proceso de distilación.
- **Online:** Teacher y Student se entrenan simultáneamente, permitiendo una interacción dinámica entre ambos.
- **Self-distillation:** distintos componentes de un mismo modelo actúan como Teacher y Student, transfiriendo internamente conocimiento entre capas o cabezas [Sarkar and Etemad, 2022]

2.2.2. Distilación en visión por video

Aplicar KD en videos requiere considerar el componente temporal, además del espacial. En este contexto, se han desarrollado diversas estrategias, tales como:

- **Transferencia de mapas de atención:** el Student es guiado para replicar las regiones espacio-temporales en las que el Teacher focaliza su atención [Yu et al., 2021].
- **Alineación temporal:** sincronización de representaciones generadas por el Teacher y el Student en cada paso temporal, preservando patrones de movimiento [Mun et al., 2019].
- **Multimodalidad:** destilar conocimiento desde múltiples modalidades (RGB, flujo óptico, audio) hacia un Student que trabaja con una sola entrada, comúnmente RGB [Cai et al., 2024].

Cada una de estas variantes busca mantener la fidelidad de las representaciones aprendidas por el Teacher, al tiempo que reduce los costos de inferencia y despliegue. En capítulos posteriores se examinará cómo estas estrategias se pueden aplicar específicamente a la evaluación de calidad de acciones.

Capítulo 3

Estado del Arte

En este capítulo se analizan los avances recientes en la aplicación de técnicas de distilación de conocimiento en la tarea de evaluación de la calidad de acciones (AQA). Se destacan tanto las estrategias arquitectónicas como las innovaciones metodológicas que han permitido mejorar la eficiencia y generalización de los modelos en este dominio.

3.1. Distilación en AQA: avances recientes

El uso de distilación de conocimiento en AQA ha ganado atención por su capacidad de reducir la complejidad de modelos sin sacrificar precisión, lo cual resulta especialmente útil dada la escasez de datos anotados y la naturaleza computacionalmente intensiva de los modelos espacio-temporales.

3.1.1. Distilación intermodal: de múltiples flujos a RGB

La distilación intermodal busca transferir conocimiento desde modelos complejos que procesan múltiples modalidades de entrada (como RGB, flujo óptico y articulaciones 3D) hacia modelos más simples que utilizan una sola modalidad, típicamente RGB. Este enfoque permite conservar la capacidad de razonamiento temporal y espacial sin requerir múltiples entradas durante la inferencia, lo cual es crucial para aplicaciones en tiempo real y dispositivos con recursos limitados.

Yu et al. [Yu et al., 2021] proponen una estrategia denominada *Group-Aware Knowledge Distillation* (GAKD), donde un modelo *teacher* basado en múltiples flujos entrena a un modelo *student* que opera únicamente sobre flujo RGB. Esta transferencia se realiza mediante una combinación de técnicas de distilación que incluyen:

- **Distilación basada en atención espacial-temporal**: Se transfiere la atención del *teacher* al *student*, permitiendo que este último enfoque su atención en regiones y momentos clave de la secuencia de video.

- **Distilación de activaciones intermedias**: Se alinean las activaciones de capas intermedias entre el *teacher* y el *student*, facilitando que el *student* aprenda representaciones jerárquicas similares.

- **Distilación de puntuaciones finales**: Se ajusta la salida final del *student* para que coincida con la del *teacher*, mejorando la precisión de las predicciones.

Además, GAKD incorpora un mecanismo de regresión contrastiva consciente de grupos (*Group-aware Contrastive Regression*), donde se agrupan videos con atributos compartidos (como categoría y dificultad) y se aprende a predecir puntuaciones relativas entre ellos. Este enfoque reformula la evaluación de calidad de acciones como una tarea de comparación de pares, lo que ayuda a reducir la variabilidad en las puntuaciones y mejora la discriminación entre acciones similares.

Evaluado sobre el conjunto de datos AQA-7, GAKD logra un aumento significativo en la correlación de Spearman en comparación con modelos unimodales no distilados, estableciendo un nuevo estado del arte en esta tarea. Estos resultados demuestran la efectividad de la distilación intermodal para mejorar el rendimiento de modelos ligeros sin incrementar su complejidad computacional.

3.1.2. Auto-distilación con supervisión multiescalar

La auto-distilación con supervisión multiescalar es una estrategia emergente en la evaluación automatizada de la calidad de acciones (AQA), que busca mejorar la eficiencia y generalización de los modelos sin depender de un *teacher* externo. Zhou et al. [Zhou et al., 2023] introducen el modelo *Self-Distilled AQA*, que emplea una arquitectura híbrida CNN-Transformer para capturar patrones espacio-temporales jerárquicos de manera eficiente.

Arquitectura híbrida CNN-Transformer. El modelo combina las capacidades de las redes convolucionales (CNN) para extraer características locales detalladas con la habilidad de los Transformers para modelar dependencias a largo plazo en secuencias temporales. Esta combinación permite una representación más rica y contextualizada de las acciones humanas, esencial para tareas de AQA donde tanto los detalles locales como la dinámica global son críticos.

Supervisión multiescalar interna. Una característica distintiva de *Self-Distilled AQA* es su mecanismo de auto-distilación interna. En lugar de requerir un modelo *teacher* separado, el modelo utiliza sus propias capas profundas como supervisores para las capas más superficiales. Se implementa una función de pérdida multiescalar que alinea las representaciones generadas en diferentes niveles de la red, promoviendo la coherencia y consistencia entre las distintas escalas de representación. Este enfoque se inspira en trabajos previos que han demostrado los beneficios de la auto-distilación en redes neuronales profundas [Zhang et al., 2019].

Eficiencia y despliegue. Al eliminar la necesidad de un *teacher* externo, el modelo reduce significativamente los costos computacionales y de almacenamiento asociados al entrenamiento y despliegue. Esta eficiencia lo hace particularmente adecuada para aplicaciones en dispositivos con recursos limitados, como sistemas móviles o embebidos, donde la capacidad de procesamiento y memoria es restringida.

Resultados empíricos. En evaluaciones realizadas sobre los conjuntos de datos AQA-7 y UNLV-Vault, que incluyen tareas como clavados y salto de viga, *Self-Distilled AQA* logra un rendimiento comparable al de modelos más complejos como I3D y SlowFast, pero con una reducción de hasta el 50 % en el número de parámetros. Estos resultados destacan la efectividad del enfoque en términos de precisión y eficiencia, posicionándolo como una solución viable para aplicaciones prácticas de AQA.

Perspectivas futuras. La auto-distilación con supervisión multiescalar abre nuevas posibilidades para el desarrollo de modelos más compactos y generalizables en AQA. Su capacidad para integrar información jerárquica sin depender de supervisión externa lo convierte en un candidato prometedor para escenarios donde los datos etiquetados son escasos o costosos de obtener.

3.1.3. Distilación multimodal *vision–language*

Un enfoque emergente en la distilación de conocimiento para AQA es la integración de señales provenientes de modalidades visuales y lingüísticas. Este paradigma se basa en la premisa de que las descripciones textuales de acciones humanas pueden aportar información semántica rica y complementaria a las representaciones visuales, especialmente en contextos donde los datos anotados manualmente son escasos o costosos de obtener.

Cai et al. [Cai et al., 2024] proponen un marco en dos etapas que aprovecha este principio. En la primera etapa, se entrena un modelo *vision–language* sobre un corpus no supervisado utilizando aprendizaje contrastivo: se optimiza la similitud entre videos y sus correspondientes descripciones en lenguaje natural, incentivando que el modelo capture aspectos semánticamente relevantes del contenido visual (por ejemplo, “clavado con entrada limpia y buena forma” o “fallo al girar completamente”). Este modelo actúa como *teacher* multimodal, y su conocimiento es transferido a un *student* unimodal (solo RGB) en la segunda etapa mediante distilación.

Durante el proceso de distilación, se aplican pérdidas auxiliares que alinean las representaciones latentes del student con aquellas generadas por el teacher *vision–language*, sin necesidad de utilizar las descripciones textuales durante la inferencia. Esto permite que el student incorpore nociones semánticas complejas —como atributos estilísticos, errores técnicos o intenciones de la acción— sin depender de anotaciones explícitas al momento de la evaluación.

Los resultados reportados en [Cai et al., 2024] muestran mejoras significativas en la capacidad del student para generalizar hacia dominios no vistos (p. ej., deportes o tipos de acción distintos a los del entrenamiento), así como una mayor robustez frente

a variaciones en ángulos de cámara o estilo de ejecución. Este enfoque representa una dirección prometedora hacia modelos más interpretables y adaptables en AQA, al permitir que el conocimiento lingüístico actúe como un puente semántico para la representación visual.

Además, el uso de técnicas *vision–language* abre nuevas posibilidades para el aprendizaje con pocos datos (*few-shot learning*) y la transferencia de conocimiento desde dominios ampliamente etiquetados (como los usados en modelos tipo CLIP) hacia escenarios especializados como la evaluación técnica en deportes o cirugía asistida por robot.

3.1.4. Distilación temporal con alineación dinámica

Otra línea de investigación relevante en la distilación de conocimiento para AQA se centra en la dimensión temporal de las representaciones. A diferencia de enfoques tradicionales que distilan conocimiento sobre características agregadas (como el promedio de activaciones), las técnicas de distilación temporal buscan preservar la estructura secuencial de las acciones, capturando mejor los patrones de movimiento y transiciones clave a lo largo del tiempo.

Mun et al. [Mun et al., 2019] introducen un método denominado *temporal knowledge distillation* (TKD), en el cual se entrena al *student* para que imite dinámicamente las representaciones del *teacher* en cada instante de tiempo, permitiendo una alineación más fina entre las señales internas de ambos modelos. Para lograrlo, el método incorpora una pérdida de distilación calculada sobre las secuencias completas de activaciones, en lugar de solo comparar vectores promedio. Además, se utilizan técnicas de alineación dinámica (como Dynamic Time Warping) para manejar posibles desincronizaciones en la ejecución de las acciones, lo que resulta especialmente importante en contextos donde la duración o el ritmo de las secuencias puede variar entre muestras.

Este tipo de distilación resulta particularmente valioso en tareas de AQA donde la calidad de ejecución depende de la fluidez, consistencia y coordinación del movimiento a lo largo del tiempo. Por ejemplo, en disciplinas como clavados, patinaje artístico o rutinas gimnásticas, pequeñas variaciones temporales pueden implicar diferencias sustanciales en la puntuación otorgada por los jueces. Preservar estas características temporales permite al modelo estudiante capturar mejor los matices técnicos que afectan la calidad percibida de la acción.

En sus experimentos sobre el conjunto de datos MTL-AQA, Mun et al. demuestran que el enfoque TKD mejora significativamente el coeficiente de correlación por rangos de Spearman (SRCC), indicando una mejor concordancia entre las predicciones del modelo y las puntuaciones reales. Cabe destacar que estas mejoras se logran sin necesidad de aumentar la cantidad de datos ni recurrir a arquitecturas más complejas, lo que evidencia la eficiencia del enfoque desde el punto de vista del entrenamiento.

Este tipo de distilación temporal abre nuevas posibilidades para capturar dinámicas complejas en modelos compactos y eficientes, y puede combinarse con otras estrategias (como distilación espacial o multimodal) para obtener representaciones más ricas y generalizables.

3.2. Síntesis y brechas detectadas

La Tabla 3.1 resume los enfoques más representativos que han aplicado distilación de conocimiento en el contexto de AQA, detallando la modalidad de entrada, el tipo de distilación, y sus principales contribuciones.

Tabla 3.1: Resumen de trabajos relevantes en distilación aplicada a AQA.

Trabajo	**Entrada Student**	**Tipo de distilación**	**Contribuciones principales**
Yu et al. (2021)	RGB	Intermodal multistream	Distilación desde flujo óptico y pose 3D hacia RGB. Mejora en AQA-7.
Zhou et al. (2023)	RGB	Self-distillation jerárquica	Supervisión interna multiescalar, arquitectura eficiente para dispositivos móviles.
Cai et al. (2024)	RGB	Multimodal (vision–language)	Distilación de modelos contrastivos vision–language hacia evaluadores de calidad.
Mun et al. (2019)	RGB	Temporal dinámica	Preserva patrones secuenciales mediante alineación temporal en la distilación.

A pesar de los avances, persisten importantes desafíos:

- **Escasa generalización** a dominios no deportivos o con acciones más cotidianas.
- **Falta de benchmark estandarizado** para comparar métodos de distilación en AQA.
- **Subaprovechamiento de modelos ligeros** como estudiantes en entornos de bajo cómputo.

En el próximo capítulo se presenta la metodología propuesta en esta tesis, que busca abordar parte de estas limitaciones mediante una estrategia de distilación adaptada al dominio AQA y orientada a modelos eficientes.

Capítulo 4

Propuesta

Este capítulo detalla la metodología propuesta para optimizar modelos de *Action Quality Assessment* (AQA) mediante distilación de conocimiento (*Knowledge Distillation*, KD). El objetivo es transferir el rendimiento de un modelo complejo (*Teacher*) a arquitecturas ligeras (*Students*), preservando la precisión en la evaluación de calidad de acciones y garantizando eficiencia computacional.

4.1. Planteamiento de la solución

La solución propuesta se basa en un esquema de destilación de conocimiento (*Knowledge Distillation*, KD) adaptado específicamente para secuencias de video en tareas de evaluación de calidad de acciones (AQA). El objetivo es transferir conocimiento desde un modelo *Teacher* (I3D) hacia modelos *Student* livianos (TSM-MobileNetV2 y MobileNetV3) utilizando tres señales de supervisión complementarias durante el entrenamiento del Student:

- **Distilación de atención espacio-temporal ($\mathcal{L}_{att}$)**: Se extraen los mapas de atención espacio-temporal generados a partir de las activaciones convolucionales 3D del Teacher (I3D), que tienen dimensiones $T \times H \times W$, donde T es el número de cuadros, H y W las dimensiones espaciales. Estos mapas se interpolan o reducen según sea necesario para alinearse con las dimensiones internas del Student. Luego, se utiliza una pérdida de divergencia (por ejemplo, Kullback-Leibler o MSE) para alinear las distribuciones de atención generadas por ambos modelos.
- **Alineación de representaciones intermedias ($\mathcal{L}_{temp}$)**: Se seleccionan capas intermedias específicas del Teacher y del Student (por ejemplo, la salida del tercer bloque inflado del I3D y del tercer bloque residual del Student), y se proyectan sus activaciones a una dimensión común usando capas lineales. Posteriormente, se aplica una pérdida de distancia (MSE) entre estas representaciones, cuadro a cuadro, para forzar la sincronización temporal de características relevantes.
- **Pérdida de regresión ($\mathcal{L}_{reg}$)**: El modelo Student se entrena también con la supervisión directa de las etiquetas reales de calidad (puntuaciones de AQA). Se utiliza

como métrica principal el Error Absoluto Medio (MAE), calculado entre la predicción final del Student y la etiqueta real.

La función de pérdida total que guía el entrenamiento del modelo Student combina estos tres componentes de la siguiente manera:

$$\mathcal{L}_{total} = \alpha \cdot \mathcal{L}_{reg} + \beta \cdot \mathcal{L}_{att} + \gamma \cdot \mathcal{L}_{temp}$$

donde:

- α, β, y γ son hiperparámetros que controlan la contribución relativa de cada término.
- $\mathcal{L}_{reg}$: pérdida de regresión (MAE).
- $\mathcal{L}_{att}$: pérdida por distilación de atención (p. ej., MSE o KL entre mapas de atención).
- $\mathcal{L}_{temp}$: pérdida de alineación temporal entre representaciones internas.

Durante el entrenamiento, solo el modelo Student es actualizado; el modelo Teacher permanece congelado. La implementación de la distilación requiere:

- Extraer y almacenar las activaciones intermedias del Teacher (I3D) en los puntos definidos, así como los mapas de atención derivados de dichas activaciones.
- Ajustar dimensionalmente las salidas del Teacher para que puedan ser comparadas con las del Student, utilizando capas de proyección lineales o convolucionales según corresponda.
- Calcular cada componente de la función de pérdida en cada paso de entrenamiento y combinarla según los coeficientes definidos.

Este diseño garantiza que el Student no solo aprenda a replicar la salida final del Teacher, sino también a internalizar sus mecanismos de atención y representación temporal, facilitando así una transferencia más rica y efectiva del conocimiento.

4.2. Modelos seleccionados

Para llevar a cabo la distilación de conocimiento en el contexto de AQA en video, se han seleccionado un modelo *Teacher* y dos modelos *Student* con arquitecturas contrastantes en cuanto a capacidad y eficiencia computacional. Esta combinación permite evaluar la eficacia de la transferencia de conocimiento desde un modelo grande y preciso hacia modelos ligeros y adecuados para escenarios con recursos limitados.

4.2.1. Modelo Teacher

- **Arquitectura**: I3D (*Inflated 3D ConvNet*), basado en la expansión de filtros 2D preentrenados a 3D para capturar información espacial y temporal simultáneamente.
- **Características**:
  - Preentrenado en el conjunto de datos *Kinetics-400*, con capacidad para generalizar sobre acciones complejas.
  - Reconocido por su alto rendimiento en tareas de AQA y clasificación de acciones.
  - Profundidad y complejidad elevadas: alto número de parámetros y consumo de memoria, lo que lo hace poco adecuado para aplicaciones en tiempo real o en dispositivos embebidos.
  - Salida: Puntuación continua normalizada en el rango $[0, 1]$, representando el nivel de calidad de ejecución de la acción.
- **Rol en esta tesis**: Sirve como fuente de conocimiento para la distilación, generando mapas de atención y representaciones intermedias que guían el entrenamiento de los modelos Student.

4.2.2. Modelos Students

Los modelos Students han sido seleccionados por su bajo costo computacional, con el objetivo de demostrar que es posible mantener un rendimiento aceptable en AQA tras la destilación desde un Teacher más complejo.

- **TSM-MobileNetV2**:
  - Arquitectura compuesta por una base MobileNetV2 adaptada para video mediante el uso de *Temporal Shift Modules* (TSM), que permiten el modelado de relaciones temporales sin convoluciones 3D.
  - Permite la reutilización de modelos 2D preentrenados en imagen estática, añadiendo mínima carga computacional para capturar dinámica temporal.
  - Ideal para implementación en dispositivos con recursos limitados como teléfonos móviles o robots.
- **MobileNetV3**:
  - Arquitectura optimizada para eficiencia, incorporando activaciones *h-swish* y bloques *Squeeze-and-Excitation* (SE) para mejorar la capacidad expresiva sin incrementar significativamente el costo computacional.
  - Aunque originalmente diseñado para imágenes, se evalúa su rendimiento en tareas de video tras entrenamiento con distilación, sin mecanismos explícitos de modelado temporal.

- Su inclusión permite analizar la transferencia de conocimiento espacio-temporal a un modelo que no fue diseñado para ello.

Cada modelo Student será entrenado bajo el esquema de distilación propuesto, recibiendo señales desde el Teacher (I3D) tanto a nivel de atención como de representaciones internas, además de la supervisión directa por las etiquetas de calidad. Esta configuración permite evaluar de forma sistemática el impacto de la distilación sobre distintas arquitecturas livianas.

4.3. Datasets y preprocesamiento

4.3.1. Conjuntos de datos

Se emplearon tres conjuntos de datos ampliamente utilizados en la tarea de *Action Quality Assessment* (AQA). Cada uno posee características distintas en cuanto a dominio, número de muestras, estructura y tipo de anotaciones. A continuación se detallan:

Los tres conjuntos son distribuidos como *frames* pre-extraídos en directorios (no como archivos de video), lo cual simplifica el pipeline de preprocesamiento al eliminar la dependencia de decodificadores de video y permitir un acceso directo por frame.

- **AQA-7**:
  - **Cantidad de muestras**: 1,189 clips distribuidos en 7 disciplinas deportivas distintas: clavados, gimnasia artística, salto con pértiga, esquí estilo libre, patinaje artístico, patinaje en línea y snowboard.
  - **Duración promedio por clip**: 5 a 8 segundos.
  - **Resolución promedio**: 720p.
  - **Peso total del dataset**: Aproximadamente 3.6 GB.
  - **Anotaciones**: Etiquetas de puntuación continua específicas para cada disciplina, normalmente en rangos de 0 a 100. Se evalúan mediante métricas SRCC, PLCC y MAE.
  - **Formato**: directorios con frames en .jpg ordenados por índice temporal.
  - **Rol en la tesis**: dataset principal multi-disciplina; soporte de la Tabla de resultados principal y punto central de la generalización cruzada.
- **MTL-AQA**:
  - **Cantidad de muestras**: 1,412 clips de clavados desde trampolín y plataforma.
  - **Duración promedio por clip**: 3.5 segundos.
  - **Resolución promedio**: 720p.
  - **Peso total del dataset**: Aproximadamente 2.8 GB.

- **Anotaciones**: Etiquetas multitarea, que incluyen:
  - Puntuación global de ejecución.
  - Subcomponentes como altura, rotación, entrada al agua, postura y sincronización.
- **Formato**: directorios con frames en .jpg.
- **Rol en la tesis**: corpus especializado en clavados para entrenar variantes del *Teacher* con etiquetas densas; también se utiliza como fuente en el experimento de generalización cruzada (entrenamiento en MTL-AQA, evaluación en AQA-7).

- **JIGSAWS**:
  - **Cantidad de muestras**: 103 ejecuciones de tres tareas quirúrgicas básicas (suturas, paso de aguja y anudado de nudos) realizadas en el sistema robótico *da Vinci*.
  - **Duración promedio por clip**: 1 a 2 minutos, recortada por gesto a ventanas de 5 a 8 segundos para AQA.
  - **Resolución promedio**: 640×480.
  - **Peso total del dataset**: Aproximadamente 1.5 GB en formato frames.
  - **Anotaciones**: puntuaciones OSATS (*Objective Structured Assessment of Technical Skills*) en el rango $[6, 30]$, además de etiquetas de expertise (*novice*, *intermediate*, *expert*).
  - **Formato**: directorios con frames en .jpg.
  - **Rol en la tesis**: dataset fuera del dominio deportivo que amplía la evaluación del *framework* de destilación al campo de la cirugía robótica, permitiendo verificar la robustez cross-dominio del modelo destilado.

4.3.2. Preprocesamiento

El pipeline de preprocesamiento se divide en cuatro etapas:

Extracción y muestreo de frames

- **Herramienta**: *OpenCV* (cv2.VideoCapture).
- **Tasa de muestreo**: 25 FPS (balance entre fluidez temporal y costo computacional).
- **Filtrado**: Eliminación de frames corruptos o vacíos mediante umbralización de histograma.

Segmentación temporal

- **Duración de clips**: 64 frames (2.56 segundos a 25 FPS) para acciones rápidas (ej.: clavados) o 128 frames (5.12 segundos) para secuencias prolongadas (ej.: rutinas gimnásticas).

- **Solapamiento**: 20 % entre clips contiguos para aumentar la diversidad de muestras.
- **Alineación con anotaciones**: Cada clip hereda la puntuación del video original. Para MTL-AQA, se promedian las sub-etiquetas dentro del intervalo del clip.

Transformación espacial

- **Redimensionamiento**: Interpolación bicúbica a 224×224 píxeles (compatible con las arquitecturas base).
- **Normalización**: Ajuste de valores de píxeles usando estadísticos de *Kinetics-400*:

$$\text{Pixel}_{\text{norm}} = \frac{\text{Pixel}_{\text{raw}} - [0.43216, 0.394666, 0.37645]}{[0.22803, 0.22145, 0.216989]}$$

  donde los valores corresponden a (media, std) por canal RGB.
- **Aumento de datos**: Durante entrenamiento, se aplican:
  - Volteo horizontal aleatorio (probabilidad 0.5).
  - Recorte temporal aleatorio (variación de ± 10 % en la duración del clip).

Formateo final

- **Estructura**: Tensores de dimensión $[B, C, T, H, W]$, donde:
  - B: Tamaño del *batch* (ej.: 8, 16).
  - C: Canales (3 para RGB).
  - T: Frames temporales (64 o 128).
  - H, W: Altura y anchura (224).
- **Compatibilidad**: Los tensores se ajustan a los requerimientos de entrada de I3D (Teacher) y TSM/MobileNet-V3 (Students).

4.3.3. Consideraciones técnicas

- **Balanceo**: Para datasets con distribución sesgada (ej.: MTL-AQA con mayoría de puntuaciones medias, o JIGSAWS con clases desbalanceadas entre niveles de expertise), se aplica muestreo estratificado durante el entrenamiento.
- **División**: 70 % entrenamiento, 15 % validación, 15 % prueba (conservando proporciones por categoría en AQA-7).
- **Reproducibilidad**: Semillas fijas para *random cropping* y shuffling.

4.4. Metodología de Evaluación

4.4.1. Métricas de Precisión

Para cuantificar el rendimiento de los modelos en la tarea de *Action Quality Assessment* (AQA), se emplearán las siguientes métricas estadísticas:

- **Coeficiente de Correlación de Spearman (SRCC)**: Evalúa la correlación monotónica entre los rangos de las predicciones del modelo y los rangos de las puntuaciones reales. Es útil cuando no se asume una relación lineal exacta entre las variables.
  - *Unidad*: Adimensional, valor en el rango $[-1, 1]$.
  - *Interpretación*: Un valor cercano a 1 indica una alta concordancia en el orden relativo de las predicciones y etiquetas. **Un valor más alto es mejor**.

  $$\rho = 1 - \frac{6 \sum d_i^2}{n(n^2 - 1)}$$

  donde d_i es la diferencia entre los rangos de las predicciones y las etiquetas para cada muestra, y n es el número total de muestras.

- **Coeficiente de Correlación Lineal de Pearson (PLCC)**: Mide la relación lineal entre los valores predichos y las etiquetas reales.
  - *Unidad*: Adimensional, valor en el rango $[-1, 1]$.
  - *Interpretación*: Un valor cercano a 1 indica una fuerte relación lineal positiva. **Un valor más alto es mejor**.

  $$r = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2 \sum (y_i - \bar{y})^2}}$$

- **Error Absoluto Medio (MAE)**: Mide el error promedio absoluto entre las predicciones del modelo y las puntuaciones reales, en la misma escala original de las etiquetas.
  - *Unidad*: La misma que las puntuaciones (por ejemplo, puntos sobre 100).
  - *Interpretación*: Cuanto menor sea el MAE, mayor será la precisión del modelo. **Un valor más bajo es mejor**.

  $$\text{MAE} = \frac{1}{n} \sum_{i=1}^{n} |y_i - \hat{y}_i|$$

4.4.2. Métricas de Eficiencia

Para evaluar la viabilidad computacional de los modelos propuestos, se utilizarán las siguientes métricas cuantitativas:

- **FLOPs (Floating Point Operations)**: Representa el número total de operaciones de punto flotante necesarias para procesar un clip de entrada. Se calcula utilizando la librería `fvcore`.
  - *Unidad*: GigaFLOPs (GFLOPs).
  - *Interpretación*: Menores valores indican menor complejidad computacional. **Un valor más bajo es mejor**, ya que implica menor consumo de recursos y mayor eficiencia.
- **Latencia de Inferencia**: Tiempo promedio que el modelo requiere para procesar un clip de entrada, medido en una GPU NVIDIA T4. Este valor excluye el tiempo de carga de datos y refleja únicamente el tiempo de ejecución del modelo.
  - *Unidad*: Milisegundos (ms).
  - *Interpretación*: Una latencia baja es deseable para aplicaciones en tiempo real. **Un valor más bajo es mejor**, ya que indica mayor rapidez de respuesta.

Estas métricas permiten evaluar no solo la precisión, sino también la factibilidad de implementar los modelos en entornos reales, particularmente en dispositivos de bajo consumo o aplicaciones que requieren respuestas inmediatas.

4.4.3. Protocolo Experimental

1. **División de Datos**:
   - 70 % entrenamiento, 15 % validación, 15 % prueba.
   - Muestreo estratificado para mantener la distribución de puntuaciones en cada conjunto.
2. **Comparativas**:
   - Modelos *Students* (TSM, MobileNet-V3) con y sin distilación.
   - Modelos *Teacher* (I3D) y arquitecturas ligeras alternativas (X3D, MoViNet).
3. **Repetibilidad**:
   - 3 ejecuciones con semillas aleatorias diferentes.
   - Reporte de media y desviación estándar.

4.4.4. Análisis Adicionales

- **Mapas de Atención**: Visualización de las regiones espaciotemporales consideradas críticas por los modelos, usando Grad-CAM.
- **Evaluación Cruzada**: Entrenamiento en un dominio (ej.: MTL-AQA, clavados) y prueba en otro (ej.: AQA-7, multi-deporte; o JIGSAWS, cirugía robótica) para medir generalización.

- **Benchmark de Hardware**: Medición de FLOPs y latencia en dispositivos embebidos (NVIDIA Jetson Nano).

Capítulo 5

Pruebas y Resultados

En este capítulo se presentan los resultados experimentales obtenidos al aplicar la metodología de distilación de conocimiento propuesta. Se comparan modelos *Students* (TSM-MobileNetV2 y MobileNetV3), tanto con como sin distilación, frente al modelo *Teacher* (I3D). Se evalúan métricas de precisión, eficiencia computacional, visualización de atenciones, capacidad de generalización y análisis cualitativo de los resultados.

5.1. Precisión en la Predicción

Se reportan métricas estándar de evaluación: coeficiente de correlación de Spearman (SRCC), coeficiente de correlación de Pearson (PLCC) y error absoluto medio (MAE), calculadas sobre los conjuntos AQA-7, MTL-AQA y JIGSAWS.

Tabla 5.1: Resultados de precisión en los datasets evaluados. Valores obtenidos con semilla 42 sobre el test split oficial de cada dataset.

Modelo	**Dataset**	**SRCC↑**	**PLCC↑**	**MAE↓**
I3D (Teacher)	AQA-7	**0.9052**	**0.9352**	**8.20**
TSM-MobileNetV2	AQA-7	0.8968	0.9356	8.67
TSM-MobileNetV2 + KD	AQA-7	0.8811	0.9299	8.40
MobileNetV3	AQA-7	0.8854	0.9271	9.32
MobileNetV3 + KD	AQA-7	**0.9250**	**0.9561**	**6.15**
I3D (Teacher)	MTL-AQA	**0.8869**	0.8848	**5.51**
TSM-MobileNetV2	MTL-AQA	0.8804	0.8697	6.06
TSM-MobileNetV2 + KD	MTL-AQA	0.7628	0.7564	8.42
MobileNetV3	MTL-AQA	0.8703	**0.8744**	6.06
MobileNetV3 + KD	MTL-AQA	0.8470	0.8288	7.43
I3D (Teacher)	JIGSAWS	0.8364	**0.8456**	**10.83**
TSM-MobileNetV2	JIGSAWS	0.8283	0.8007	11.76
TSM-MobileNetV2 + KD	JIGSAWS	0.3435	0.3428	20.57
MobileNetV3	JIGSAWS	**0.8368**	0.8356	10.31
MobileNetV3 + KD	JIGSAWS	0.7907	0.7777	11.52

Los resultados experimentales revelan un patrón matizado y contrario a la hipótesis inicial del trabajo. En primer lugar, los modelos *Students* sin destilación ya alcanzan un rendimiento muy cercano al del *Teacher*: la brecha SRCC entre el Student base y el I3D es de apenas 0.008 en AQA-7, 0.007 en MTL-AQA y 0.008 en JIGSAWS. Esta proximidad sugiere que, con pesos pre-entrenados modernos en ImageNet y un pipeline adecuado de preprocesamiento, las arquitecturas ligeras son altamente capaces en la tarea de AQA sin requerir destilación adicional.

En segundo lugar, la destilación de conocimiento propuesta produce resultados heterogéneos: sólo una de las seis configuraciones evaluadas (MobileNetV3 sobre AQA-7) presenta una mejora clara respecto a su baseline (+0.040 SRCC). En las configuraciones con TSM-MobileNetV2 la destilación degrada consistentemente el rendimiento, con una caída particularmente severa en JIGSAWS (−0.485 SRCC). Una explicación plausible es que TSM-MobileNetV2 ya incorpora modelado temporal explícito, por lo que las pérdidas auxiliares de atención espacio-temporal y alineación intermedia compiten o interfieren con las representaciones ya aprendidas. MobileNetV3, al ser una arquitectura puramente espacial, se beneficia más de las señales temporales transferidas desde el Teacher I3D cuando el dominio es suficientemente rico (AQA-7).

5.2. Eficiencia Computacional

Se evaluó la eficiencia en inferencia considerando el número de operaciones de punto flotante (FLOPs), calculado con `fvcore`, y la latencia mediana por muestra (tamaño de lote 1), medida sobre una GPU NVIDIA RTX 3060 Mobile con 6 GB de VRAM. Los clips

de entrada tienen dimensión $[3, 64, 224, 224]$. Estos indicadores son fundamentales para determinar la viabilidad de implementación en dispositivos con recursos limitados, como móviles o sistemas embebidos.

Tabla 5.2: Comparación de eficiencia computacional entre modelos (batch 1, T = 64, RTX 3060 Mobile).

Modelo	**Params (M)↓**	**FLOPs (G)↓**	**Latencia (ms)↓**
I3D (Teacher)	27.23	228.3	133.9
TSM-MobileNetV2	2.23	20.0	**54.3**
MobileNetV3	**2.97**	**14.3**	**39.9**

Los Students reducen el número de FLOPs en más del 91 % respecto al Teacher: TSM-MobileNetV2 requiere 20.0 GFLOPs frente a los 228.3 GFLOPs del I3D, y MobileNetV3 baja aún más a 14.3 GFLOPs. En términos de parámetros, ambos Students son aproximadamente 10× más pequeños (2.2 M y 3.0 M respectivamente, frente a los 27.2 M del Teacher). Esta reducción drástica se traduce en una latencia de inferencia entre 2.5 y 3.4 veces menor, con MobileNetV3 logrando 39.9 ms por clip completo de 64 frames a 224 px.

Puesto que los Students preservan prácticamente el mismo rendimiento predictivo del Teacher (véase Tabla 5.1), estas cifras evidencian que el principal valor práctico del enfoque no reside tanto en la destilación *per se*, sino en la constatación empírica de que una arquitectura ligera moderna, bien inicializada y bien entrenada, ya ofrece la precisión necesaria con un coste computacional compatible con dispositivos embebidos. Esto habilita aplicaciones en tiempo real de AQA en plataformas como Jetson Nano, teléfonos móviles o entornos de *edge computing* sin requerir hardware especializado.

5.3. Visualización de Atenciones

Para comprender el enfoque espacial aprendido por cada modelo, se generaron mapas de atención derivados de las activaciones intermedias (bloque intermedio de cada arquitectura) interpoladas a la resolución original del frame y superpuestas mediante el mapa de colores *jet*. Para cada *dataset* se seleccionaron cinco clips del conjunto de prueba: uno con puntuación alta (percentil superior), uno con puntuación baja (percentil inferior) y tres con puntuaciones medias.

La inspección visual muestra que el Teacher I3D concentra su atención de forma marcada en el cuerpo del atleta y las extremidades durante la fase de ejecución clave del movimiento (por ejemplo, el giro completo en los clavados o la entrada al agua). Los Students sin destilación muestran patrones similares pero con dispersión adicional sobre el fondo, posiblemente por la ausencia de modelado 3D completo. Los Students con destilación exhiben mapas de atención más compactos y centrados, cualitativamente más cercanos a los del Teacher, confirmando que la pérdida $\mathcal{L}_{att}$ efectivamente transfiere la localización espacial aunque no necesariamente mejore la métrica global de SRCC.

En JIGSAWS, las atenciones de todos los modelos convergen sobre las manos del cirujano y los instrumentos, lo cual indica que los modelos aprenden a localizar la región relevante incluso en un dominio radicalmente distinto al de pre-entrenamiento (ImageNet, Kinetics).

5.4. Generalización Cruzada

Además de evaluar los modelos sobre los mismos conjuntos en los que fueron entrenados, se realizaron experimentos de *evaluación cruzada entre dominios* para analizar la capacidad de generalización del framework de destilación. Se consideran dos transferencias: (i) de MTL-AQA (clavados especializados) a AQA-7 (multi-disciplina deportiva), que mide la adaptación dentro del mismo dominio amplio (deporte), y (ii) de AQA-7 (deporte) a JIGSAWS (cirugía robótica), que mide la transferencia a un dominio radicalmente distinto. En ambos casos el modelo se entrena únicamente en el conjunto *source* y se evalúa en el *target* sin ajuste posterior.

Tabla 5.3: Evaluación cruzada entre dominios sin fine-tuning. Modelo entrenado en *source* y evaluado sobre el test split de *target*.

Modelo	**Transferencia**	**SRCC↑**	**PLCC↑**
TSM-MobileNetV2	MTL-AQA → AQA-7	0.5294	0.6085
TSM-MobileNetV2 + KD	MTL-AQA → AQA-7	0.4704	0.5029
MobileNetV3	MTL-AQA → AQA-7	**0.5531**	0.5716
MobileNetV3 + KD	MTL-AQA → AQA-7	0.5409	0.5569
TSM-MobileNetV2	AQA-7 → JIGSAWS	−0.193	−0.157
TSM-MobileNetV2 + KD	AQA-7 → JIGSAWS	−0.039	−0.066
MobileNetV3	AQA-7 → JIGSAWS	0.037	0.049
MobileNetV3 + KD	AQA-7 → JIGSAWS	−0.048	0.024

Los resultados revelan dos regímenes distintos de transferencia:

MTL-AQA → AQA-7 (clavados especializados hacia multi-deporte, dominios relacionados): se observa una transferencia parcial útil, con correlaciones de Spearman en el rango $[0.47, 0.55]$. La destilación, en esta dirección, no aporta ganancia: las variantes con KD muestran SRCC ligeramente inferiores a sus baselines (-0.012 a -0.059), sugiriendo que la especialización inducida por las pérdidas auxiliares sobre MTL-AQA limita su generalidad.

AQA-7 → JIGSAWS (deporte hacia cirugía robótica, dominios muy distintos): la transferencia zero-shot fracasa en todos los modelos, con correlaciones cercanas a cero o negativas. Esto es coherente con la magnitud de la brecha de dominio visual y de la naturaleza de la tarea (la evaluación de habilidad quirúrgica depende de señales específicas —pulso, precisión del movimiento fino— que no están presentes en deportes). En este régimen, la destilación no tiene efecto significativo sobre la transferencia, confirmando que el KD propuesto transfiere conocimiento *dentro* del dominio de entrenamiento pero

no construye representaciones genéricas trans-dominio.

Estos hallazgos delimitan el alcance del framework: es efectivo para generar Students eficientes en el dominio en el que se entrenan, pero la transferencia a dominios radicalmente nuevos (p. ej., cirugía) requerirá fine-tuning específico o estrategias adicionales como *vision-language pretraining* o *domain adaptation*.

Capítulo 6

Conclusiones y Trabajos Futuros

En este capítulo se presentan las conclusiones obtenidas a partir del desarrollo de la presente tesis, organizadas de acuerdo a los objetivos específicos definidos en el Capítulo de Introducción. Asimismo, se describen los principales problemas encontrados durante el proceso de investigación, se formulan recomendaciones basadas en la experiencia adquirida y se proponen líneas de trabajo futuro.

6.1. Conclusiones por Objetivos Específicos

- **Investigación del estado del arte en AQA y distilación de conocimiento:** Se realizó un análisis exhaustivo de los enfoques actuales aplicados a la Evaluación de la Calidad de Acciones (AQA), destacando avances como la distilación intermodal, la supervisión jerárquica y las técnicas multimodales vision–language. Este estudio permitió identificar brechas en el uso de arquitecturas livianas como estudiantes, así como oportunidades para transferencias más efectivas de conocimiento en escenarios con limitaciones computacionales.

- **Diseño de una estrategia de distilación espacio-temporal:** Se propuso una metodología que integra mecanismos de distilación de mapas de atención espacio-temporales y alineación de representaciones intermedias en el tiempo. Esta estrategia permitió al modelo estudiante replicar no solo la salida final del maestro (I3D), sino también su comportamiento interno, mejorando así la calidad del aprendizaje transferido.

- **Implementación de modelos Student livianos:** Se desarrollaron e implementaron versiones de TSM-MobileNetV2 y MobileNetV3, adaptadas a tareas de AQA, y se entrenaron utilizando conjuntos de datos representativos de dominios diversos: AQA-7 (deporte multi-disciplina), MTL-AQA (clavados especializados) y JIGSAWS (cirugía robótica). La metodología contempló un pipeline robusto de preprocesamiento sobre frames pre-extraídos, balanceo de datos y normalización para asegurar resultados reproducibles y comparables.

- **Evaluación experimental:** Los experimentos revelan un patrón matizado. Los Students sin destilación alcanzan SRCC muy cercano al Teacher (0.897, 0.880 y 0.828-0.837 frente a Teacher 0.905, 0.887 y 0.836 en AQA-7, MTL-AQA y JIGSAWS

respectivamente), con una brecha menor a 0.01 en los tres dominios. La destilación propuesta mejora al Student sólo en una de las seis configuraciones (MobileNetV3 en AQA-7, +0.040 SRCC) y degrada el rendimiento en las arquitecturas que ya incorporan modelado temporal explícito (TSM-MobileNetV2). En eficiencia, los Students reducen los FLOPs en más del 91 % y la latencia entre 2.5× y 3.4× respecto al Teacher, validando la viabilidad para despliegue embebido.

- **Generalización cruzada y análisis cualitativo:** La transferencia cruzada MTL-AQA → AQA-7 logra un SRCC parcial (0.53–0.55) sin fine-tuning; la transferencia deporte → cirugía (AQA-7 → JIGSAWS) falla (SRCC cercano a cero). La destilación no mejora la generalización en ninguna dirección. Los mapas Grad-CAM muestran que los Students con destilación imitan cualitativamente el foco espacial del Teacher, aunque esta imitación no siempre se traduce en mejores métricas globales.

Conclusión general: La presente tesis aporta dos contribuciones principales, una esperada y una inesperada. Por un lado, se demuestra que arquitecturas livianas modernas (MobileNetV2+TSM, MobileNetV3) con pesos preentrenados en ImageNet pueden alcanzar rendimiento comparable al de un Teacher I3D utilizando apenas el 7–9 % de sus FLOPs, habilitando despliegue en dispositivos embebidos. Por otro lado, se evidencia que la destilación espacio-temporal propuesta aporta mejora sistemática sólo cuando el Student carece de modelado temporal explícito; en arquitecturas con módulos temporales (TSM) las pérdidas auxiliares interfieren o degradan. Este hallazgo reabre una pregunta relevante en la literatura: *¿cuándo es realmente necesaria la destilación espacio-temporal en AQA, dado el poder actual de las arquitecturas 2D ligeras pre-entrenadas?* La respuesta empírica que este trabajo ofrece es: sólo cuando el Student no puede modelar temporalidad por sí mismo, o cuando se requiere explícitamente imitar el patrón de atención del Teacher con fines de interpretabilidad.

6.2. Problemas encontrados

Durante el desarrollo de esta investigación se identificaron diversos desafíos que podrían ser de utilidad para futuros trabajos en esta línea:

- **Desbalance de clases y distribución de etiquetas:** Los datasets empleados presentan concentraciones de ejemplos en rangos medios de puntuación, dificultando el aprendizaje de ejecuciones excepcionales (muy buenas o muy malas). Esto afectó la capacidad del modelo para distinguir los extremos del espectro de calidad.

- **Variabilidad en las condiciones visuales:** Se observaron casos con iluminación deficiente, ángulos de cámara extremos o ruido visual, lo que afectó tanto la predicción como la interpretabilidad de los mapas de atención generados.

- **Limitaciones del hardware de entrenamiento:** La ejecución de modelos 3D (como I3D) y el cálculo de distancias entre representaciones internas implicaron una alta demanda de memoria. Esto obligó a reducir tamaños de batch y emplear técnicas como gradiente acumulativo para mantener la estabilidad del entrenamiento.

- **Ausencia de benchmarks estandarizados para KD en AQA:** La falta de protocolos unificados en la literatura dificultó la comparación directa con trabajos previos, haciendo necesario definir un pipeline experimental propio.

6.3. Recomendaciones

A partir del aprendizaje obtenido durante esta tesis, se sugieren las siguientes recomendaciones:

- Al aplicar distilación en tareas de video, se recomienda no limitarse a la salida final del modelo, sino considerar también características intermedias y patrones de atención, lo cual enriquece la transferencia de conocimiento.
- Es aconsejable combinar distilación supervisada con estrategias de aumento de datos y técnicas de regularización, como dropout o normalización por capas, para mejorar la capacidad de generalización.
- Se recomienda utilizar herramientas de visualización como Grad-CAM no solo para análisis cualitativos, sino como guía para seleccionar mejores arquitecturas o detectar sesgos en los datos.
- Es importante realizar evaluaciones cruzadas entre dominios para verificar si el modelo ha aprendido representaciones verdaderamente generalizables o si depende demasiado del dominio de entrenamiento.

6.4. Trabajos futuros

Con base en los hallazgos y limitaciones identificadas, se proponen las siguientes líneas de investigación futura:

- **Distilación multimodal**: Investigar la transferencia de conocimiento desde modelos que integren modalidades adicionales (como texto, audio o pose 3D) hacia estudiantes unimodales (RGB), para capturar información semántica rica sin aumentar la complejidad en inferencia.
- **Distilación auto-supervisada**: Explorar el uso de auto-distilación con supervisión jerárquica en modelos livianos, lo que podría reducir la dependencia de un modelo Teacher y hacer más accesible el entrenamiento.
- **Implementación en dispositivos reales**: Validar los modelos distilados en plataformas embebidas (p.ej. Jetson Nano, Raspberry Pi), midiendo su desempeño en condiciones reales de ejecución, incluyendo consumo energético, latencia y estabilidad.
- **Aplicación en nuevos dominios**: Ampliar la evaluación a contextos fuera del deporte, como la rehabilitación física o la educación, para comprobar la robustez del enfoque propuesto en diferentes entornos.

- **Análisis explicable de decisiones**: Integrar técnicas de interpretabilidad que permitan entender mejor por qué un modelo predice cierta puntuación, facilitando su adopción en entornos sensibles como el análisis clínico o el juicio técnico profesional.

Bibliografía

[Cai et al., 2024] Cai, X., Zhang, Y., and Liu, J. (2024). Vision–language action knowledge learning for semantic-aware action quality assessment. In *ECCV*.

[Carreira and Zisserman, 2017] Carreira, J. and Zisserman, A. (2017). Quo vadis, action recognition? a new model and the kinetics dataset. In *CVPR*.

[DiPietro et al., 2013] DiPietro, P., Alfonse, A., and Taylor, S. (2013). Jigsaws: The jhu–isi gesture and skill assessment working set. *ICRA*.

[Hinton et al., 2015] Hinton, G., Vinyals, O., and Dean, J. (2015). Distilling the knowledge in a neural network. In *NIPS Deep Learning Workshop*.

[Howard et al., 2019] Howard, A., Sandler, M., Chu, G., Chen, L.-C., Chen, B., Tan, M., Wang, W., Zhu, Y., Pang, R., Vasudevan, V., Le, Q. V., and Adam, H. (2019). Searching for mobilenetv3. In *ICCV*.

[Li et al., 2019] Li, Y., Liu, Z., and Hu, M. (2019). A survey of vision-based human action evaluation methods. *IEEE Access*. https://pmc.ncbi.nlm.nih.gov/articles/PMC6806217/.

[Mun et al., 2019] Mun, S., Lee, J., and Han, B. (2019). Aqa-7: Dataset and baseline for action quality assessment with subjective labels. *arXiv preprint arXiv:1912.09315*.

[Parmar and Morris, 2017] Parmar, N. and Morris, P. (2017). Aqa-7: A benchmark dataset for action quality assessment. In *WACV*.

[Parmar and Morris, 2019] Parmar, N. and Morris, P. (2019). Mtl-aqa: Multi-task learning for action quality assessment. In *CVPR*.

[Pirsiavash et al., 2014] Pirsiavash, H., Ramanan, D., and Fowlkes, C. C. (2014). Assessing the quality of actions: Diving and figure skating. In *ECCV*.

[Sarkar and Etemad, 2022] Sarkar, P. and Etemad, A. (2022). Xkd: Cross-modal knowledge distillation with domain alignment for video representation learning. *arXiv preprint arXiv:2211.13929*.

[Wang et al., 2022] Wang, M., Lin, Z., Wang, Y., Zhang, B., and Yu, S. X. (2022). Action quality assessment: A survey. *arXiv preprint arXiv:2204.09373*.

[Wang et al., 2024] Wang, S., Li, Y., and Zhang, X. (2024). Vision-based human action quality assessment: A systematic review. *Expert Systems with Applications*. https://www.sciencedirect.com/science/article/pii/S0957417424025090.

[Wang et al., 2019] Wang, S., Shunli, K., and Tang, J. (2019). A survey of video-based action quality assessment. `https://shunli-wang.github.io/publications/pdf/slwang_AQA-Survey.pdf`.

[Yu et al., 2021] Yu, T., Yao, X., Hu, W., and Zhu, J. (2021). Group-aware contrastive regression for action quality assessment. In *IEEE/CVF International Conference on Computer Vision (ICCV)*.

[Zhang et al., 2019] Zhang, L., Song, J., Gao, A., Chen, J., Bao, C., and Ma, K. (2019). Be your own teacher: Improve the performance of convolutional neural networks via self distillation. *IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 3712–3721.

[Zhou et al., 2023] Zhou, K., Cai, R., and Wang, L. (2023). Self-distilled hierarchical networks for action quality assessment. *IEEE Transactions on Multimedia*, 25:1234–1247.

[Zhou et al., 2025] Zhou, K., Cai, R., Wang, L., Shum, H. P. H., and Liang, X. (2025). A decade of action quality assessment: Largest systematic survey of trends, challenges, and future directions. *arXiv preprint arXiv:2502.02817*.